

Crítica: Matrix Factorization Techniques for Recommender Systems

En este paper vemos distintas técnicas para factorizaciones de matrices. La factorización de matrices se ha mostrado como una herramienta útil para sistemas recomendadores, con gran importancia en el famoso Netflix Prize. Permiten hacer representaciones abstractas de los gustos de usuarios según ciertos factores, además de evaluaciones de los ítems en base a esos mismos factores. Se han mostrado como con buena escalabilidad y precisión.

Lo primero que me llamó la atención fue la mención de la técnica de Alternating Least Squares (ALS). Es una técnica que nunca había escuchado y me interesa su potencial en distintas áreas. Sería interesante ver un análisis de los beneficios que entrega este algoritmo versus otras características deseadas como puede ser la precisión. ¿Los resultados son distintos? ¿Cuál es mejor? ¿Hay aleatoriedad en esa respuesta? Por otro lado, Stochastic Gradient Descent puede trabajar con batches donde igual tiene capacidades de paralelización.

Por otro lado, en la ecuación 5 se habla de la función que se busca minimizar:

$$\min_{p^*, q^*, b^*} \sum_{(u,i) \in \mathcal{K}} (r_{ui} - \mu - b_u - b_i - p_u^T q_i)^2 + \lambda (\|p_u\|^2 + \|q_i\|^2 + b_u^2 + b_i^2) \quad (5)$$

Pero no me queda claro la necesidad de agregar los biases y el promedio a la ecuación. ¿Éstos no son constantes, o por lo menos fijas para una instancia de la base de datos? También puede ser que se agreguen con el único fin de aclarar el cálculo que se está realizando, o para entregar un valor comparativo entre, por ejemplo, un usuario con dos ítems distintos.

Con respecto a las dinámicas temporales, creo que sería interesante analizar otros datos implícitos que solo se ven presentes en este contexto no estático. Por ejemplo, si un usuario modifica el rating de algún ítem anterior, se podría considerar, no solo los ajustes de los biases y promedios, si no también buscar la causa de ese cambio de gusto, dado que podría indicar que otras cosas similares a ese ítem también bajen en su preferencia.

Por último, se podría intentar predecir cambios antes de qué ocurran. Si un cambio en gusto es causado por el contenido que consumo, se podría ver una tendencia de cambios de gusto al consumir un ítem, y predecir a priori que los usuarios que consuman ese ítem cambiarán sus gustos de la misma manera que la tendencia.

Alejandro Quiñones